

Stimulussanajoukkojen luomisen automatisointi monikielisistä FastText-kielikirjastoista

Aaro Kuusinen

Perustieteiden korkeakoulu

Special Assignment

Espoo 04.06.2015

Vastuupettaja:

Prof. Riitta Salmelin

Työn ohjaaja:

TkT Tiina Lindh-Knuutila

Tekijä: Aaro Kuusinen		
Työn nimi: Stimulussanajoukkojen luomisen automatisointi monikielisistä FastText-kielikirjastoista		
Päivämäärä: 04.06.2015	Kieli: Suomi	Sivumäärä: 5+27
Koulutusohjelma: Life science technologies		
Vastuuopettaja: Prof. Riitta Salmelin		
Työn ohjaaja: TkT Tiina Lindh-Knuutila		
Tässä erikoistyössä kehitettiin tutkimusryhmälle työkalu (eng. pipeline), joka automatisoi N400-ärsykkeinä käytettävien sanakolmikoiden (alustus-alustus-kohde) tuottamisen. Taustalla on tarve esittää sanat kontrolloiduissa semanttisissa konteksteissa ja vähentää manuaaliseen valikointiin liittyvää työmäärää sekä käännöksissä ilmeneviä ongelmia kuten polysemiaa, asiayhteyden muutosta ja kulttuurieroja. Työkalu hyödyntää FastText-sanamalleja ryhmän toiveen mukaisesti Word2Vecin sijaan, suorittaa sanojen suodatusta, luokittelua sekä perusmuotoistamista Stanzalla, mittaa semanttista samankaltaisuutta kosinietäisyyksillä sekä käyttää KMeans-ryhmittelyä apunaan sanojen valinnassa. Tuloksena tuotettiin ihmisen lopulta validoimat sanajoukot suomeksi, englanniksi ja ruotsiksi. Validoinnin jälkeen noin kymmenes sanoista ja kolmasosa kolmikoista karsiutui, joten tavoitemäärään pääsemiseksi on syytä tuottaa ylimääräisiä kolmikkokandidaatteja. Uudet sanajoukot kaikilla kolmella kielellä vastasivat alkuperäistä suomenkielistä sanajoukkoa suhteellisen hyvin vaikkakin eri etäisyysluokat keskittyivät tiiviimmin kuin alkuperäisessä. Näin myös vaikuttaa siltä että kullekin kielelle suoraan tuotettu sanajoukko vastaa vähintäänkin kääntämällä tuotettua joukkoa. Työkalu siis toimii johdonmukaisesti useilla kielillä ja tarjoaa säästöä manuaalisessa työssä säilyttäen tutkimukselle keskeiset kontrollit.		
Avainsanat: FastText, sanavektori, sanaupotus, sanakolmikko, N400, monikielisyys, PCA, KMeans, t-SNE, automaatio, semantiikka, kosinietäisyys, Python		

Author: Aaro Kuusinen

Title: Automation of generating stimuli from multilingual FastText models

Date: 04.06.2015

Language: Finnish

Number of pages: 5+27

Degree programme: Life Science Technologies

Supervisor: Prof. Riitta Salmelin

Advisor: D.Sc. (Tech.) Tiina Lindh-Knuutila

In this special assignment, a pipeline was developed for automating the generation of word triplets (primer-primer-target) used as N400 stimuli. Behind this is a need to show words in a controlled semantic context, to lessen the manual labour involved picking the words and to reduce the problems involved in translating those words into other languages (polysemia, changing context, cultural differences).

The pipeline utilizes FastText-embeddings instead of Word2Vec according to the wishes of the research group. It filters the candidate words, classifies and lemmatizes them with Stanza, measures their respective semantic similarities using cosine distance and uses KMeans clustering as a tool in selecting the words. As a result, word sets were created in three languages, Finnish, English and Swedish. After validating the sets, roughly a tenth of the words and a third of the triplets were discarded. Hence in order to gain the targeted amount, it is suggested to aim at a higher number of triplets. The new sets in all three languages matched the original Finnish words relatively well even though the distribution of the different distance categories was more concentrated than in the original. It seems that the word sets generated directly in a said language are better than sets generated via translation. The pipeline offers a consistent way to generate word sets in multiple languages while saving time and maintaining control over the selection criteria.

Keywords: FastText, word vector, word embedding, word triplet, N400, multilingual, PCA, KMeans, t-SNE, automation, semantic, cosine distance, Python

Sisällysluettelo

Tiivistelmä	ii
Tiivistelmä (englanniksi)	iii
Sisällysluettelo	iv
Tekoälytyökalujen käyttö	v
1 Johdanto	1
2 Tutkimustehtävä ja -kysymykset	3
3 Menetelmien tausta	4
3.1 Vektoriavaruusmallit ja sanaupotukset	4
3.2 Semanttinen etäisyys	5
3.3 Dimensiopudotusmenetelmät	5
3.4 Klusterointimenetelmät	6
3.5 Perusmuotoistus ja sanaluokkien tunnistus	7
4 Työkalun toiminta	8
4.1 Esikäsittely	9
4.2 Kohdesanat	10
4.3 Alustussanat	12
4.4 Validointi	13
5 Tulokset	16
6 Yhteenveto	19
Viitteet	21
A Kootut ajoparametrit ja muut tiedot	24
B Eri kielten kuvaajia	27

Tekoälytyökalujen käyttö

Tämän raportin kielenhuoltoon ja rakenteelliseen muokkaukseen hyödynnettiin pienissä määrin suureen kielimalliin perustuvaa avustajaa. Tekoäly ei tuottanut tutkimusdataa, sanajoukkoja, analyysejä eikä vaikuttanut tieteellisiin johtopäätöksiin. Kaikki sisältö on tekijän tarkistamaa ja hyväksymää.

1 Johdanto

Luettua tekstiä käsitellessä aivomme päätyvät käsittelemään monimutkaisia kielellisiä ja visuaalisia ärsykeitä. Osa tästä käsittelystä liittyy muotojen havainnointiin ja osa kielelliseen ymmärrykseen [21]. Muotojen tunnistaminen kirjaimiksi ja sanoiksi sekä vielä myöhemmin näiden sanojen merkityksen liittäminen mielen sisäiseen sanakirjaan on pohja, jolle sanojen ja niiden merkityksen ymmärtäminen rakentuu [6]. Tutkiessaan tätä sanojen merkitysten ymmärtämistä, Ghazaryan et al., jonka työhön tämä erikoistyö nojaa, on esittänyt koehenkilöille sarjan sanoja, samalla mitaten aivojen aktiivisuutta magnetoenkefalografilla (MEG) [Ghazaryan et al. julkaisematon käsikirjoitus]. Esitetyt sanat oltiin valittu siten, että peräkkäin esitettyjen sanojen semanttiset etäisyydet vaihtelivat halutulla tavalla. Esittäen sanoja täten erilaisissa konteksteissa ryhmä on toivonut tuovan sanoille kontekstia, joka puolestaan voisi lisätä sanojen semanttista prosessoinnin selkeyttä aivoissa [10], [16].

Esittäessään sanoja kontekstissa, ryhmä on tutkinut N400-vastetta. Kyseessä on herätevaste, joka esiintyy noin 400 millisekunnin kuluttua ärsykkeestä [15]. Tähän vasteeseen pystytään järjestelmällisesti vaikuttamaan esimerkiksi miellehtymän vahvuudella, sanojen tuttuudella ja asiayhteyden ennustettavuudella [8]. Vaikka N400-vasteen tarkasta toiminnallisesta roolista ei ole täyttä yksimielisyyttä, tässä yhteydessä sen ajatellaan yleisimmin liittyvän sanojen semanttiseen käsittelyyn ja merkityksen integraatioon [15], [8], [24]. Sanastollinen käsitys on, että tämän vasteen voimakkuus vastaa sanan merkityksen hakemisen vaikeutta mielen sisäisestä sanastosta. Eli voimakkaampi vaste kuvaa suurempaa haastetta merkityksen hakemisessa ja pienempi puolestaan hakemisen helppoutta. Tähän merkityksen hakemisen vaikeuteen voidaan kuitenkin vaikuttaa alustamalla sanalle kontekstia esimerkiksi aikaisemmilla sanoilla, aivan kuten ryhmä on tehnyt.

Ghazaryan et al. tutkimuksessa koehenkilöille näytetyt sanat ovat olleet peräkkäisiä kolmen sanan joukkoja, mistä kaksi ensimmäistä sanaa ovat niin sanottuja “primer”- eli alustussanoja ja kolmas “target”- eli kohdesana. Tutkimuksessa kolmikoiden luonti aloitettiin valitsemalla kohdesanoiksi 70 yleistä suomenkielistä substantiivia, joista 35 olivat abstrakteja ja 35 konkreettisia. Tämä valikointityö toteutettiin manuaalisesti ja sanoja pyrittiin valikoimaan eri kategorioista. Sanojen valikoinnin jälkeen hyödynnettiin esikoulutettua Word2Vec-mallia (W2V), josta jokaiselle sanalle saatiin sitä kuvaava vektori. Samaa mallia hyödynnettiin laskemaan kunkin sanan etäisyys suomenkielen yleisimpiin 15 000:een substantiiviin. Etäisyyden mittana käytettiin sanoja kuvaavien vektorien kosinietäisyyksiä. Kohdesanat eivät olleet mukana tässä laajemmassa sanajoukossa joukossa. Nämä yleisimmät 15 000 sanaa jaettiin kunkin kohdesanan kohdalla kolmeen kategoriaan riippuen sanan etäisyydestä kohdesanaan. Nämä kolme kategoriaa olivat:

- Läheiset (samankaltaisimmat 0,25%)
- Kohtalaisen läheiset (samankaltaisimmat 0,5 - 1%)
- Kaukaiset (kauempana kuin samankaltaisimmat 10%)

Kullekin näistä uusista sanoista (toiset alustussanat) puolestaan laskettiin vastavalla metodilla yksi läheinen sana. Tuloksena oli joukko sanakolmikoita, joissa molemmat alustussanat ovat hyvin lähellä toisiaan semanttisesti mutta toisen alustussanan ja kohdesanan etäisyys vaihteli halutulla välillä. Näistä kolmikoista manuaalisesti valikoitiin jokaista kohdesanaa ja tämän etäisyyskategoriaa toiseen alustussanaan kohden neljä kolmikkoo. Ja näin tuloksena saatiin 840 ainutlaatuista sanakolmikkoo. Alkuperäiset kolmikot on sittemmin käännetty myös englanniksi ja osittain myös ruotsiksi.

Kuitenkin näiden tutkimuksessa käytettyjen sanakolmikoiden käsin luominen on ollut työlästä ja vaativaa. Lisäksi kääntäessä alunperin toiselle kielelle luotua sanastoa, ilmenee ongelmia kuten polysemiaa, asiayhteyden muuttumista sekä kulttuurillisia eroja sanojen merkityksissä. Näihin tutkimusaukkoihin vastaaminen on ollut tämän erikoistyön tarkoitus luomalla uusi työkalu helpottamaan sanakolmikoiden luomista mahdollisesti jopa usealla kielellä. Raportissa käydään läpi oleellisten metodien taustaa, työkalun toimintaa, siihen liittyviä valintoja sekä lopussa vertaillaan Ghazaryan et al. alkuperäistä sanajoukkoa sekä sen käännöksiä työkalulla tuotettuihin joukkoihin. Vertailukohtina toimivat pääosin sanakolmikoiden etäisyyskategorioiden ulkomuoto, jakautuminen sekä lopullisten työkalun validoinnista selviävien sanojen ja kolmikoiden määrä.

2 Tutkimustehtävä ja -kysymykset

Ghazaryan et al. tutkimuksessa lähes jokainen sana on erikseen katsottu lävitse ja kolmikot vielä lopussa tarkastettu sekä valittu. Tämän erikoistyön tuloksena kehitettiin työkalu tämän prosessin automatisoimiseksi niin pitkälle kuin suinkin mahdollista. Tavoitteena oli lisäksi tämän prosessin monikielellisen toteutuksen mahdollistaminen. Työssä keskityttiin FT-mallien hyödyntämiseen, sillä valmiiksi opetetut monikieliset FT-mallit mahdollistavat kielten välisesti vertailukelpoisten sanvektorien käytön sekä tukevat hyvin morfologisesti rikkaita kieliä.

Olennaisia tutkimuskysymyksiä:

- Miten työkalun tuottamat sanajoukot eroavat alkuperäisistä?
- Mitkä parametrit käyttäjän tulisi voida määritellä?
- Miten ja missä kohdin ihminen validoi sanoja?
- Toimiiko työkalu eri kielillä?
- Ovatko työkalulla tuotetut sanajoukot parempia kuin kääntämällä tuotetut?

3 Menetelmien tausta

3.1 Vektoriavaruusmallit ja sanaupotukset

Modernit luonnollisen kielen käsittelyn menetelmät hyödyntävät usein sanaupotuksia (eng. word embeddings), joissa sanat esitetään numeerisina vektoreina moniulotteisessa avaruudessa [1], [17]. Menetelmät perustuvat distributionaalisen semantiikan periaatteeseen, jonka mukaan sanojen merkitystä voidaan aproksimoida niiden käyttöympäristöjen perusteella [23]. Ajatuksena on, että samankaltaisissa konteksteissa esiintyvät sanat saavat keskenään samankaltaiset vektoriesitykset. Nämä vektoriupotukset mahdollistavat luonnollisten kielten käsittelyn ja analyysin matemaattisin keinoin.

Word2Vec-mallissa (W2V) sanat opetetaan vektoreiksi neuroverkkopohjaisella menetelmällä siten, että malli pyrkii ennustamaan sanan ympärillä esiintyviä sanoja tai vaihtoehtoisesti ennustamaan ympäröivistä sanoista keskeisimmän sanan [19]. Opetuksen tuloksena syntyy vektoriavaruus, jossa jokaista opetuksessa käytettyä sanaa kuvastaa omanlaisensa vektori. W2V-mallit ovat staattisia eivätkä kykene muodostamaan vektoreita mallin ulkopuolisille sanoille, ns. Out-Of-Vocabulary sanoille (OOV) [11]. Malli on myös tämän myötä herkkä kirjoitusvirheille ja vaihteleville kirjoitusasuille, joka lisäksi vaikeuttaa morfologisesti rikkaiden kielten, kuten suomen käsittelyä. Morfologisesti rikkaissa kielissä sanojen kirjoitusasu, muoto ja taivutus muuttuu kontekstista riippuen. Mutta staattisten yksiselitteisten vektorien ansiosta W2V-mallien käsittely vaatii huomattavasti vähemmän muistia verrattaen esimerkiksi FastText-malliin.

FastText-malli (FT) laajentaa W2V-mallia hyödyntämällä sanojen sisäistä rakennetta. Malli pilkkoo sanat osasanoihin eli n-grammeihin, joiden perusteella lopullinen sanavektori muodostetaan [5]. Tämän sanojen pilkkomisen ansiosta FT-malli kykee muodostamaan vektoriesityksiä myös sellaisille sanoille, joita ei esiintynyt mallin opetusaineistossa, eli OOV-sanoille. Tämä ominaisuus on erityisen hyödyllinen morfologisesti rikkaiden kielten käsittelyssä ja ei ole yhtä herkkä kirjoitusvirheille ja muille vaihteleville kirjoitusasuille kuten W2V-malli. Mutta tämä osasanojen hyödyntäminen johtaa raskaampaan laskennallisuuteen ja suurempaan muistin käyttöön.

FT-mallissa sanat ovat valmiiksi järjestettynä näiden esiintymistiheyden mukaiseen järjestykseen. Eli listan kärjessä olevat sanat ovat yleisempiä kuin pidemmällä listassa olevat. Tämä järjestys ei tosin ota huomioon sitä että yhden sanan eri taivutusmuodot voivat esiintyä eri tiheyksillä ja täten tämä ei täysin vastaa sanan todellista esiintymistiheyttä. Mutta listan järjestys toimii suhteellisen hyvänä arviona sanojen keskinäiselle yleisyydelle ja tätä ominaisuutta tullaankin hyödyntämään työkalun toiminnassa. Mallin sisältämät sanat ovat opetusaineiston mukaisessa formaatissaan eli esimerkiksi erinäisissä taivutusmuodoissa. Useimmat FT-mallit on koulutettu sekä Common Crawl- että Wikipedia-aineistoilla [9].

Sanavektorimallien toiminta riippuu kuitenkin voimakkaasti opetusaineiston laadusta ja koosta. Mallit oppivat tilastollisia yhteyksiä eivätkä varsinaisesti ymmärrä

sanojen merkityksiä. Tästä syystä ne voivat sisältää opetusaineistossa esiintyviä vinoumia sekä yhdistää sanoja toisiinsa tavoilla, jotka eivät aina vastaa ihmisen semanttista intuitiota.

3.2 Semanttinen etäisyys

Koska sanoilla, on vektoriupotuksissa omat vektoresityksensä, voidaan sanojen semanttista etäisyyttä mitata esimerkiksi kosinietäisyydellä. Tämä semanttisen kontekstin peilaaminen vektoriupotuksen ominaisuuksiin perustuu jo aiemmin esitettyyn distributionaalisen semantiikan periaatteeseen. Kosinietäisyys on määritetty täten:

$$\text{dist}(\mathbf{A}, \mathbf{B}) = 1 - \cos(\theta) = 1 - \frac{\mathbf{A} \cdot \mathbf{B}}{|\mathbf{A}||\mathbf{B}|} \quad (1)$$

missä $\mathbf{A}$ ja $\mathbf{B}$ kuvaavat sanojen vektoresityksiä, $\mathbf{A} \cdot \mathbf{B}$ on näiden pistetulo ja $|\mathbf{A}|$ sekä $|\mathbf{B}|$ ovat vektorien pituudet.

Semanttisessa laskennassa vektoresitykset on usein L2-normalisoitu, jolloin laskutoimitus tiivistyy vektorien väliseen pistetuloon. Tästä on tullut standardi menetelmä vektoriupotuksien käsittelyssä semanttisessa kontekstissa, mitä erinäiset tutkimuksetkin tukevat [3], [20], [7]. Osaltaan kosinietäisyys on vakiintunut mitta sanavektorien vertailussa, koska se mittaa vektorien suuntaa riippumatta niiden pituudesta, mikäli vektorit on L2-normalisoitu, ja korreloi usein hyvin semanttisen samankaltaisuuden kanssa [13].

Kosinietäisyyden arvo lähestyy arvoa 0 silloin, kun vektorit osoittavat samaan suuntaan ja sanat ovat semanttisesti samankaltaisia. Suuremmat arvot puolestaan kuvaavat heikompa samankaltaisuutta ja täten suurempaa etäisyyttä. L2-normitettuna menetelmän etuna on sen riippumattomuus vektorien itseisarvoisista pituuksista, jolloin tarkastelu kohdistuu ensisijaisesti sanojen suhteellisiin sijainteihin vektoriavaruudessa. Normalisoidessa sanojen vektorit menetetään hieman informaatiota mutta usein vektorin pituus on korreloi sanan yleisyyden tai jonkin muun tässä tapauksessa ei oleellisen ominaisuuden kanssa [2].

3.3 Dimensiopudotusmenetelmät

Sanavektorit ovat tyypillisesti satojen ulottuvuuksien kokoisia, mikä vaikeuttaa niiden visualisointia ja voi hidastaa myöhempiä laskennallisia operaatioita huomattavasti. Tämän vuoksi eri dimensiopudotusmenetelmät ovat suosittuja niin laskennallisessa mielessä mutta myös visualisaatioissa.

Pääkomponenttianalyysi (Principal Component Analysis, PCA) on lineaarinen dimensiopudotusmenetelmä, joka muodostaa alkuperäisestä aineistosta uusia ortogonaalisia komponentteja siten, että ensimmäiset komponentit selittävät mahdollisimman suuren osan aineiston vaihtelusta. PCA:ta käytetään usein kohinan

vähentämiseen sekä aineiston rakenteen tiivistämiseen pienempään ulottuvuuteen. PCA priorisoi datan globaaleja rakenteita lokaalien ylitse sekä olettaa lineaarisia riippuvuuksia. [12]

t-SNE (t-distributed Stochastic Neighbor Embedding) on epälineaarinen visualisointimenetelmä, jonka tarkoituksena on säilyttää aineiston paikalliset naapuruussuhteet mahdollisimman hyvin kaksi- tai kolmiulotteisessa avaruudessa [26]. Menetelmä soveltuu erityisesti korkeaulotteisten aineistojen visualisointiin, mutta sen tuloksia tulee tulkita varoen, sillä menetelmä ei pyri säilyttämään aineiston globaaleja etäisyyksiä luotettavasti [26].

3.4 Klusterointimenetelmät

KMeans on iteratiivinen klusterointialgoritmi, jonka tavoitteena on jakaa aineisto ennalta määritellyyn määrään ryhmiä siten, että saman ryhmän pisteet sijaitsevat mahdollisimman lähellä ryhmän keskipistettä eli sentroidia [18]. Algoritmi toimii alustamalla ensin ryhmien keskipisteet, minkä jälkeen jokainen piste liitetään lähimpään ryhmään. Tämän jälkeen ryhmien keskipisteet päivitetään vastaamaan ryhmän pisteiden keskiarvoa. Prosessia toistetaan, kunnes ryhmät eivät enää merkittävästi muutu.

KMeans toimii erityisen hyvin tilanteissa, joissa aineisto sisältää selkeitä ja suhteellisen pallomaisia ryhmittymiä. Menetelmä on kuitenkin herkkä valitulle klusterimäärälle, sillä se pitää määrittää etukäteen. Lisäksi menetelmä olettaa pallomaisesti jakautuneita klustereita, jotka eivät aina ole taattuja. Klusterien optimaalisen määrän arvioimiseksi on tarjolla useita menetelmiä, kuten siluettikerroin tai elbow-menetelmä.

Siluettikerroin arvioi klusteroinnin laatua vertaamalla pisteiden etäisyyksiä oman klusterinsa pisteisiin sekä lähimmän klusterin pisteisiin eri klusterimäärillä. Suuri siluettikerroin viittaa tilanteeseen, jossa klusterit ovat samanaikaisesti sekä sisäisesti yhtenäisiä että toisistaan hyvin erottuvia. [4]

Myös elbow-menetelmässä tarkastellaan klusterien sisäistä hajontaa eri klusterimäärillä. Klusterien määrän kasvaessa hajonta pienenee, mutta pienentyminen hidastuu tietyn pisteen jälkeen. Tätä kohtaa kutsutaan kyynärpääkohdaksi (eng. elbow), ja sitä voidaan käyttää sopivan klusterimäärän arviointiin. [25]

Hierarkkinen klusterointi on myös yksi mahdollinen klusterointimenetelmä. Tässä menetelmässä aluksi jokainen piste on oma klusterinsa ja iteroinnin edetessä lähimmät yhdistetään isommaksi klusteriksi, kunnes jokainen piste on samassa suuressa klusterissa [27]. Menetelmänä tämä paljastaa kunkin datasetin sisäisiä hierarkisia suhteita. Esimerkiksi ”koira”, ”kissa”, ”varis” ja ”lokki” ovat kaikki eläimiä mutta nämä sisältävät pienempiä kategorioita kuten linnut (”varis” ja ”lokki”) ja nisäkkäät (”koira” ja ”kissa”). Lisäksi etukäteen ei tarvitse määritellä klustereiden määrää. Kuitenkin hierarkkinen klusterointi on hidaskäyttöinen suurilla aineistoilla, herkempi etäisyyksien valinnalle sekä vaikeampi automatisoida hierarkkisen rakenteensa ansiosta.

3.5 Perusmuotoistus ja sanaluokkien tunnistus

Perusmuotoistamisella tai lemmatisoinnilla tarkoitetaan sanojen palauttamista niiden perusmuotoon. Esimerkiksi sanat ”juoksi”, ”juoksee” ja ”juossut” voidaan palauttaa perusmuotoon ”juosta”. Tämä helpottaa eri taivutusmuotojen yhdistämistä samaan semanttiseen käsitteeseen.

Sanaluokkien tunnistuksessa pyritään puolestaan määrittämään, kuuluuko sana esimerkiksi substantiiveihin, verbeihin tai adjektiiveihin. Tehtävä on erityisen haastava yksittäisten sanojen kohdalla ilman ympäröivää kontekstia, sillä monet sanat voivat kuulua useisiin sanaluokkiin riippuen niiden käyttökontekstista.

Stanza on eräs luonnollisten kielten prosessointiin käytettävä Python-kirjasto, joka kykenee molempiin edellä mainituista tehtävistä [22]. Kirjasto hyödyntää neuroverkkopohjaisia luonnollisen kielen käsittelyn menetelmiä ja käyttää ympäröivien sanojen kontekstia sanaluokkien tunnistamiseen [22], [13]. Stanzan eri malleille eri kielillä on siis opetettu kielen rakenne ja toiminta. Kuten vektoriupotusmallitkin, Stanzan mallit ovat alttiita opetusaineistoista kumpuaville vinoumille.

4.1 Esikäsittely

Työkalun toiminta alkaa lataamalla FT- ja Stanza-mallit valitulla kielellä. Tämän jälkeen FT-mallista otetaan käsiteltäväksi osa sanoista mutta rajoittamalla muun muassa sanojen pituutta ja varmistamalla että jokainen sana on oikea sana eikä sisällä numeroita tai muita erikoismerkkejä. Sanojen käsittely jatkuu Stanzalla kunnes jäljellä on tavoiteltu määrä perusmuotoisia substantiiveja. Stanza käy sanoja lävitse yksi kerrallaan tarkastaen onko kyseessä substantiivi ja mikäli on, perusmuotoistamalla tämän.

Taulukko 1: Käytetyt olennaiset parametrit.

Parametri	Arvo
Sanamäärä	15 000
Minimi sanapituus	4
Maksimi sanapituus	10
Sanaluokka	Substantiivi
Haetut ryhmät	250
Käytetyt ryhmät	15
Kohdesanoja per ryhmä	5
Alustussanoja per etäisyysluokka	4

Sanaluokkien tunnistuksessa Stanzalle annettiin katsottavaksi ympäröiviä sanoja, jotka toimivat eräänlaisina pseudolauseina. Syynä tähän on se, että yleisesti annetulla mallilla on hankaluuksia erottaa yksittäisen sanan luokkaa ilman ympäröivää kontekstia [13]. Nämä pseudolauseet eivät ole täydellisiä, mistä seuraa että kokonaisuutena prosessi ei ole täydellinen joten listaan päättyi sanoja, jotka eivät välttämättä olleet substantiiveja tai oikein perusmuotoistettuja.

Molemmissa tehtävissään Stanza suoriutui luotettavammin eri kielillä kuin muut vaihtoehdot, joita tutkin projektin alkuvaiheessa. Näihin lukeutui mm. NLTK (WordNetLemmatizer) ja SpaCy-kirjaston oma NLP (Natural Language Processing). Ero eri mallien toimivuudessa eri kielillä oli varsin huomattava erityisesti suomeksi, mikä saattaa selittyä suomen kielen morfologisella rikkaudella. Toinen Stanzan etu muihin tarkasteltuihin vaihtoehtoihin oli sen laaja tuki noin 70:lle kielelle sekä sen ominaisuus tarjota sekä perusmuotoistamista että sanaluokkien tunnistusta. Näiden ominaisuuksien vuoksi Stanza päätyikin työkalun lopulliseksi luokittelijaksi ja perusmuotoistajaksi.

Lopulta käytössä on 15 000:en sanan lista kullakin kielellä. Seuraavaksi kullekin sanalle haetaan FT-mallista oma vektori, jotka L2-normalisoidaan. Normalisoinnin tarkoituksena on varmistaa myöhemmin käytettävien metodien samankaltaisuus sekä kuten aiemmin mainittu, tämä on osa standardia esikäsittelyä. Täten myös ainoastaan vektorien välinen kulma vaikuttaa sanojen samankaltaisuuden laskentaan yhtenäistäen työkalun menetelmiä. Esimerkiksi KMeans hyödyntää euklidista etäisyyttä klusterien määrittämisessä ja L2-normalisoitujen vektorien kosinietäisyys kuvastaisi tällöin tätä samaa etäisyysrakennetta. Pistetulo myös vastaa aiemmin esiteltyä kosinietäisyyttä (kaava 1) jolloin etäisyyslaskenta yksinkertaistuu.


Myöhemmin hyödynnettävää KMeans-ryhmittelyä sekä t-SNE:n avulla toteutettua visualisaatiota varten sanojen ulottuvuuksia vähennetään PCA:lla. PCA myös auttaa vakauttamaan t-SNE:n tuloksia [28]. 15 000 sanan tapauksessa kullakin kolmesta kielestä ilmenee että 250-ulotteiset vektorit riittävät selittämään vaihtelevasti ~93-97% sanojen samankaltaisuuksista kuten taulukosta 2 näkee. Kuitenkaan tätä 250-ulotteista PCA-avaruutta ei hyödynnetä muualla kuin klusteroinnissa ja sanojen visualisoinnissa kuten kuvissa 4 ja 5. Tämä on varotoimenpiteenä yksittäisten sanojen mahdollisten yhteyksien kadottamista vastaan, joka ei vaikuta liikaa kumpaankaan edellämäinittuun käyttökohteeseen. Klusteroinnin tarkoituksena on kuitenkin löytää vain arvioita ryhmittymistä eikä tämä metodin tarkkuus ole suurimpia työkalua rajoittavia tekijöitä.

*Taulukko 2: PCA:n kumulatiivinen selitysvoi-
ma 250:llä komponentilla.*

Kieli	%
Suomi	93,41
Englanti	97,20
Ruotsi	93,90


4.2 Kohdesanat

Ghazaryan et al. tutkimukseen pohjautuen sanakolmikkojen rakentaminen aloitetaan ns. käänteisesti eli ensin valitaan kohdesanat, toiset alustussanat ja viimeisenä ensimmäiset alustussanat. Kohdesanojen valinta alkaa KMeans-klusteroinnilla etsien sanoista ryhmittymiä. KMeans valikoitui klusterointimenetelmäksi esimerkiksi hierarkkisen klusteroinnin ylitse sen kevyemmän laskennallisuuden sekä automatisointiin sopivampien piirteidensä takia. Klusteroinnilla etsitään ensin mahdollisia kategorioita, joista lähteä liikkeelle sanojen valinnassa. Tämän tarkoituksena on luoda lisähajontaa sanojen merkityksissä pitäen kuitenkin konteksti rajallisena. 15 000:en sanan kohdalla kaikilla kolmella kielellä 250 klusteria vaikuttaa sopivimmalta määrältä. Tämä arvio perustuu kahden menetelmän yhteistulkintaan, siluettikerroin ja elbow-kuvaaja, jotka voi nähdä kuvista 2 ja 3.




Kuva 2: Sanojen ryhmittelyn statistiikkaa siluettikertoimilla suomeksi (a), englanniksi (b) ja ruotsiksi (c).

KMeansin määrittämät klusterit (kuva 4) järjestetään niiden sisältävien sanojen yleisyyksien mediaanin mukaiseen järjestykseen. Yleisyyden mittana käytetään sanojen keskinäistä järjestystä FT-mallissa, sillä tämä kuvastaa sanojen suhteellisia yleisyyksiä kuten aiemmin kuvattu. Ja näiden järjestettyjen klusterien järjesty-



Kuva 3: Sanojen ryhmittelyn statistiikkaa elbow-kuvaajilla suomeksi (a), englanniksi (b) ja ruotsiksi (c). Optimaalinen ryhmien määrä löytyy usein pisteestä, jossa WCSS:n (Within-Cluster Sum of Squares) jyrkkä lasku tasaantuu.

valittiin ensimmäiset ennalta määritetyn luvun mukaan (katso taulukko 1). Tällä prosessilla, jossa valitaan klusterit, jotka sisältävät keskimäärin paljon käytettyjä sanoja, pyritään lisäämään valittavien sanojen tunnettuutta.



Kuva 4: Työkalun tuottamien suomenkielisten sanojen vektorien t-SNE avaruus kahdessa ulottuvuudessa havainnollistamaan sanojen ryhmittymistä. Semanttisesti samankaltaiset sanat ovat ryhmittyneenä lähelle toisiaan.

Kustakin valitusta klusterista valitaan ennalta määrätty määrä keskeisimpiä sanoja. Klusterin keskeisimmät sanat ovat ne, jotka ovat lähimpänä klusterin keskusta eli sentroidia kosinietäisyyden perusteella. Kuvan 4 klusterit voidaan nähdä väritettyinä kuvassa 5. Lopulta valitut kohdesanat poistetaan mahdollisten sanojen

listauksesta, jotta vältetään tilanteelta, jossa kohde- ja alustussana olisivat samat.



Kuva 5: Kuva on muutoin identtinen kuvan 4 kanssa mutta sanoja kuvaavat pisteet on väritetty kunkin ryhmittymän mukaan.

4.3 Alustussanat


Jäljelle jääneille sanoille lasketaan kosinietäisyys kuhunkin valittuun kohdesanaan. Kosinietäisyys valittiin metriikaksi osittain alan standardien mukaisesti mutta myös, jotta vertailukelpoisuus Ghazaryan et al. tutkimukseen säilyisi. Nämä kosinietäisyydet jaotellaan kolmeen etäisyyskategoriaan jokaiselle kohdesanalle. Lisäksi Ghazaryan et al. tutkimukseen pohjautuen etäisyyskategoriat pidetään samoina vertailukelpoisuuden takaamiseksi. Jokaisen kategorian sanat puolestaan järjestetään jälleen sanojen esiintyvyyden mukaan siten, että yleisimmät sanat olivat ensimmäisinä. Tämä jälleen osaltaan taatakseen ennestään valittavien sanojen tunnettuutta. Lopuksi jokaisesta kategoriasta valikoidaan ennalta määrätty määrä sanoja kullekin kohdesanalle (katso taulukko 1).

Valittuja toisia alustussanoja ei poisteta kaikkien sanojen listasta kesken valitsemisprosessin, joten samat sanat saattavat hyvinkin esiintyä eri sanojen alustajina. Mutta lopulliset toiset alustussanat poistetaan kaikkien sanojen listasta välttääksemme tilannetta, jossa molemmat alustussanat ovat samat.

Ensimmäisten alustussanojen valikointi tapahtuu pitkälti samoin kuin toisten alustussanojen. Jäljelläoleville sanoille lasketaan etäisyydet toisiin alustussanoihin mutta kullekin toiselle alustussanalle etsitään vain yksi sana ja tämä on lähimmästä



Kuva 7: Validoidut suomenkieliset toiset alustussanat t -SNE-avaruudessa. Sanat ovat jakaantuneet laajemmalle alueelle kuin kohdesanat kuvassa 6. Sanoja 195.



Kuva 8: Validoidut suomenkieliset ensimmäiset alustussanat t -SNE-avaruudessa. Kaikkein laajimmin levittäytyneet sanat. Sanoja 102.

Tämä jälkikäteen sanojen validointi on se miten tämä työ on lopulta tuotettu. Ja kuten kuvattu, tämän automaattisen prosessin lisäksi työkalussa on myös mahdollisuus valikoida sanoja lähes jokaisessa välissä. Tällöin lopun suuremmalle sanojen läpikäymiselle ei ole vastaavaa tarvetta. Vaihtoehtona tämä ei tosin eroa työläydestään juurikaan alkuperäisestä mallista, mitä työkalu yrittää parantaa vaikkakin se tekee prosessista mielekkään yhtenäisen. Tällä tavalla myös vältetään karsimasta prosessin lopussa mahdollisesti jopa satoja kolmikoita pois ja jokainen kolmikko käydään varmasti lävitse ja tarkastetaan sopivuudeltaan. Taulukossa 3 on havainnollistettu luvuilla tämän automatisoidun prosessin lopullisen läpikäynnin vaikutusta lopullisten sanojen ja kolmikoiden määrään. Vaikka poistettujen sanojen määrä vaihteli huomattavasti kielten välillä (suomi: 36, englanti: 39, ruotsi: 64), pysyi poistuneiden kolmikoiden määrä suhteellisen vakiona (~300). Tämä tosin on vain yhden ajokerran otos kustakin kielestä.


Taulukko 3: Validoinnin vaikutukset sanamääriin lopullisessa stimulusjoukossa.

	Suomi		Englanti		Ruotsi	
	Ennen	Jälkeen	Ennen	Jälkeen	Ennen	Jälkeen
Sanoja	399	363	461	422	394	330
Kolmikoita	900	616	900	599	900	609
Poistettuja sanoja	9,0 %		8,7 %		16,2 %	
Poistettuja kolmikoita	31,6 %		33,4 %		32,3 %	

5 Tulokset

Tämän projektin tuloksissa on vertailtu Ghazaryan et al. käyttämää alkuperäistä suomenkielistä sanajoukkoa sekä sen käännöksiä englanniksi ja ruotsiksi, niiltä osin mitä on ollut mahdollista, projektin tuloksena syntyneisiin uusiin sanajoukkoihin. Tuloksena tuotettiin uudet sanajoukot kaikilla kolmella kielellä tekijän oman kielitaidon puitteissa. Näiden sanajoukkojen vertailua alkuperäisiin sanajoukkoihin on havainnollistettu kuvissa 9, 10 ja 11. Suomeksi verrattavissa olivat lisäksi alkuperäisten sanojen W2V-vektorien etäisyydet.

Kuvasta 9 havaitaan että jo alkuperäisten sanojen kohdalla oli eroavaisuutta käytettyjen vektorimallien välillä. W2V-vektoreissa kaukaiset sanat olivat selkeästi kauempana keskimääräisesti joukkona kuin samojen sanojen vastaavat FT-vektorit. Saman tuloksen voi huomata taulukosta 4, jossa on lueteltuna etäisyyskategorioiden sanojen etäisyyksien tilastollisia lukuja. Esimerkiksi W2V-mallissa kaukaisten sanojen ryhmä on selkeästi kauempana muista ryhmistä kuin kummassakaan FT-mallissa.




Kuva 9: Valikoitujen kohdesanojen etäisyys alustussanoihin suomeksi. Alkuperäisen sanaston Word2Vec-vektorit (a), alkuperäisen sanaston FastText-vektorit (b) ja tuloksena syntyneen sanaston FastText-vektorit (c).

Taulukko 4: Kohdesanojen etäisyyskategorioiden mediaanit ja keskihajonta suomenkielisille sanoille kolmessa eri mallissa: Word2Vec, alkuperäinen FastText ja uusi FastText.

Suomi	Word2Vec		Alkup. FastText		Uusi FastText	
Alustussana	1.	2.	1.	2.	1.	2.
Läheiset μ	0,520	0,457	0,547	0,489	0,620	0,483
Koht. läheiset μ	0,616	0,589	0,612	0,593	0,672	0,576
Kaukaiset μ	0,863	0,878	0,787	0,800	0,797	0,769
Läheiset σ	0,139	0,092	0,120	0,100	0,104	0,078
Koht. läheiset σ	0,119	0,063	0,101	0,074	0,096	0,049
Kaukaiset σ	0,060	0,052	0,065	0,064	0,066	0,053

Tuloksena saatu uusi suomenkielinen sanasto vastaa suhteellisen hyvin alkuperäisen sanajoukon muotoa FT-vektorien tapauksessa (Kuvat 9b, 9c sekä Taulukko 4). Etäisyyskategorioiden keskihajonta tuotetussa sanajoukossa on jonkin verran suppeampi toisen alustussanan etäisyyden kohdalla verraten alkuperäiseen. Kohdesanojen etäisyydet ensimmäiseen alustussanaan läpi etäisyyskategorioiden ovat myös jakautuneet hieman suppeammalle alalle kuin alkuperäisillä sanoilla. Myöskään läheiset ja kohtalaisen läheiset sanat eivät etäisyyksiltään ole aivan yhtä päällekkäisiä mutta ero on minimaalinen. Samoin kaukaisten ero kohtalaisen läheisiin on kasvanut etäisyyksien keskijakauman suppenemisen myötä.

Englanniksi vertailtavissa olivat puolestaan vain alkuperäisten käännössanojen FT-vektorit ja tuotetun uuden sanaston FT-vektorit. Kuvasta 10 ja taulukosta 5 voidaan havaita molempien mallien etäisyyskategorioiden keskinäisten etäisyyksien muistuttavan toisiaan. Tosin kaukaiset sanat ovat jälleen kauempana kohtalaisen läheisistä kuten suomenkielisessäkin tapauksessa oli verratessa uutta sanajoukkoa vanhaan. Lisäksi jokainen etäisyyskategoria on siirtynyt kauemmaksi suomeen verraten molemmilla akseleilla.




Kuva 10: Valikoitujen kohdesanojen etäisyys alustussanoihin englanniksi. Alkuperäisen sanaston FastText-vektorit (a) ja tuloksena syntyneen sanaston FastText-vektorit (b).

Taulukko 5: Kohdesanojen etäisyyskategorioiden mediaanit ja keskihajonnat englanninkielisille sanoille eri malleilla: Alkuperäinen FastText ja uusi FastText.

Englanti	Alkup. FastText		Uusi FastText	
Alustussana	1.	2.	1.	2.
Läheiset μ	0,636	0,567	0,753	0,554
Koht. läheiset μ	0,706	0,685	0,804	0,663
Kaukaiset μ	0,904	0,906	0,921	0,892
Läheiset σ	0,173	0,147	0,086	0,071
Koht. läheiset σ	0,126	0,094	0,087	0,034
Kaukaiset σ	0,066	0,066	0,063	0,05

Kunkin etäisyyskategorian muoto ja jakauma puolestaan vastaavat enemmän uudessa tuotetussa englanninkielisessä sanajoukossa (Kuva 10b) vastaavaa uutta suomenkielistä sanajoukkoa (Kuva 9c). Sama ilmiö on havaittavissa myös molemmista taulukoista 4 ja 5.

Ruotsiksi saatavilla oli ainoastaan vajavainen käännetty sanasto joten tulokset koostuvat ainoastaan uudesta luodusta sanastosta. Mutta voidaan huomata kuvan 11 muistuttavan huomattavasti aikaisemmin läpikäytyjä kuvia 9c ja 10b. Erityisesti etäisyyskategorioiden muoto sekä etäisyydet jakavat samoja piirteitä eri kielillä. Verrattuna muihin aikaisemmin luotuihin sanajoukkoihin, kategorioiden sijainnit muistuttavat enemmän suomenkielisiä kuin englanninkielisiä. Tätä havaintoa tukee myös taulukko 6.



Kuva 11: Tuloksena syntyneiden valikoitujen kohdesanojen etäisyys alustussanoihin ruotsiksi.

Taulukko 6: Kohdesanojen etäisyyskategorioiden mediaanit ja keskihajonnat luoduille ruotsinkielisille sanoille.

Ruotsi	Uusi FastText	
	1.	2.
Alustussana		
Läheiset μ	0,637	0,499
Koht. läheiset μ	0,685	0,581
Kaukaiset μ	0,803	0,795
Läheiset σ	0,100	0,080
Koht. läheiset σ	0,102	0,053
Kaukaiset σ	0,089	0,071

6 Yhteenveto

Lopputuloksena syntynyt työkalu osoittautui kykeneväksi luomaan halutunlaisia sanajoukkoja ja automatisoimaan prosessia kokonaisuutena.

Ensimmäisenä tutkimuskysymyksenä oli: ”Miten työkalun tuottamat sanajoukot eroavat alkuperäisistä?”. Ja suurimpana huomattavana erona oli etäisyyskategorioiden tiiviys. Kunkin kategorian sisällä etäisyydet kohdesanasta kumpaankaan alustussanaan eivät olleet yhtä laajalta väliltä kuin alkuperäisissä joukoissa ja etäisyydet olivat myös hyvin keskitettyjä jonkin keskuksen ympärille. Toisena ilmiönä nousi samaisten etäisyyskategorioiden eroteltavuus toisistaan. Erityisesti ”kaukaiset”-sanat olivat selkeästi erillään ”kohtalaisen läheisistä”-sanoista kaikilla kielillä. Myöskään ”kohtalaisen läheiset”- ja ”läheiset”-sanat eivät kategorioina olleet yhtä päällekkäisiä. Nämä osittain saattaa selittyä aikaisemmin mainitulla pienemmällä keskihajonnalla, jolloin tiiviimmin keskitetyt kategoriat eivät ole ominaisuuksiltaan yhtä päällekkäisiä.

Millaisia parametreja käyttäjän tulisi kyetä määritellä? Lopullinen täydellinen lista kaikista määriteltävistä parametreista löytyy liitteestä [A](#) mutta taulukossa [1](#) on lueteltuna keskeisimmät, joilla vaikutettiin sanajoukkojen muodostamiseen ja lopullisten sanojen valintaan. Tämä lista syntyi iteratiivisesti työn aikana työkalua luodessa ja testatessa.

Työkalun automatisoidussa versiossa lopullinen kohta, jossa ihmisen validaatiolla oli suurin tarve ja hyöty, oli prosessin lopussa. Tämä osittain siksi että muilla keinoin prosessia ei saa tällöin nopeutettua alkuperäisestä. Vaikkakin käyttäjällä on mahdollisuus osallistua jokaisen yksittäisen sanan valintaan jokaisessa vaiheessa työkalun käyttöä näin halutessaan. Tämä loppupään validatio tosin johtaa nykyisellään 10%:n katoon sanoissa sekä noin 33%:n katoon sanakolmikoissa. Suurimpana syynä tähän ovat väärin perusmuotoistetut sanat, jotka on myös listattu liitteessä [A](#).

Työkalu myös toimii laajasti eri kielillä vaikkakin tässä erikoistyössä keskityttiin tämän havainnollistamiseen kolmella kielellä. Kullakin kielellä tuotetut sanastot ovat keskenään hyvin samankaltaisia ja suuria eroja ei ollut huomattavissa lukuun ottamatta englanninkielisten sanojen etäisyyskategorioiden systemaattista siirtymistä hieman kauemmaksi. Tosin tämä siirtymä oli havaittavissa myös jo Ghazaryan et al. käännössanastossa, joten kyseessä saattaa olla vain kielen ominaisuuksiin liittyvä ilmiö.

Tämän työn perusteella ei ole näyttöä siitä, että työkalulla tuotetut sanajoukot olisivat alkuperäisiä heikompia. Erityisesti mikäli tavoitteena on saada aikaiseksi selkeämmin toisistaan erottuvia etäisyyskategorioita, sillä tässä erottelussa se suoriutui samoilla suhteellisilla etäisyyskategorioilla erittäin hyvin. Mutta tulokset viittaavat siihen, että uudet sanajoukot ovat vertailukelpoisia alkuperäisten sanajoukkojen kanssa. Erityisesti käännössanastoihin nähden työkalun tuottamat sanastot vaikuttavat kilpailukykyisiltä.

Työkalusta löytyy myös kehitettävää vielä. Kolmasosan menetys kolmikoista validoinnin takia on suhteellisen iso osa ja tämän minimoiminen olisi yksi mahdollisista

seuraavista askeleista. Yksi vaihtoehto voisi olla verrata sanoja avoimesti saatavilla oleviin sanakirjoihin ja siten jo alkuvaiheessa suodattaa pseudosanoja pois. Samaa sanakirjamenetelmää voisi hyödyntää tarkentamaan perusmuotoistamista. Tai vaihtoehtoisesti hyödyntää sanakirjaa suoraan sanojen lähteenä mutta tällöin saatetaan menettää tieto sanojen yleisyydestä. Suomeksi olisi myös tarjolla Turun yliopistossa kehitetty Neural Parser, joka voisi olla hyödyllinen sanojen valikoinnissa [14]. Tosin tämä tukee työkalun toimintaa vain yhdellä kielellä.

Viitteet

- [1] Felipe Almeida and Geraldo Xexéo. Word Embeddings: A Survey, 2023.
- [2] Nikolay Arefyev, Pavel Ermolaev, and Alexander Panchenko. *How much does a word weigh? Weighting word embeddings for word sense induction*. 5 2018.
- [3] Mikel Artetxe, Gorka Labaka, and Eneko Agirre. A robust self-learning method for fully unsupervised cross-lingual mappings of word embeddings. In Iryna Gurevych and Yusuke Miyao, editors, *Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, pages 789–798, Melbourne, Australia, 7 2018. Association for Computational Linguistics.
- [4] Fatima Batool and Christian Hennig. Clustering with the Average Silhouette Width. *Computational Statistics & Data Analysis*, 158:107190, 2021.
- [5] Piotr Bojanowski, Edouard Grave, Armand Joulin, and Tomas Mikolov. Enriching Word Vectors with Subword Information. *Transactions of the Association for Computational Linguistics*, 5:135–146, 6 2017.
- [6] Stanislas Dehaene, Laurent Cohen, Mariano Sigman, and Fabien Vinckier. The neural code for written words: a proposal. *Trends in Cognitive Sciences*, 9(7):335–341, 7 2005.
- [7] Georgiana Dinu, Angeliki Lazaridou, and Marco Baroni. Improving zero-shot learning by mitigating the hubness problem, 2015.
- [8] Kara D Federmeier. Connecting and considering: Electrophysiology provides insights into comprehension. *Psychophysiology*, 59(1):e13940, 2022.
- [9] Edouard Grave, Piotr Bojanowski, Prakhar Gupta, Armand Joulin, and Tomáš Mikolov. Learning word vectors for 157 languages. In *Proceedings of the eleventh international conference on language resources and evaluation (LREC 2018)*, 2018.
- [10] Peter Hagoort, Lea Hald, Marcel Bastiaansen, and Karl Magnus Petersson. Integration of Word Meaning and World Knowledge in Language Comprehension. *Science*, 304(5669):438–441, 4 2004.
- [11] Franziska Horn. Context encoders as a simple but powerful extension of word2vec. In Phil Blunsom, Antoine Bordes, Kyunghyun Cho, Shay Cohen, Chris Dyer, Edward Grefenstette, Karl Moritz Hermann, Laura Rimell, Jason Weston, and Scott Yih, editors, *Proceedings of the 2nd Workshop on Representation Learning for {NLP}*, pages 10–14, Vancouver, 8 2017. Association for Computational Linguistics.
- [12] Ian T Jolliffe and Jorge Cadima. Principal component analysis: a review and recent developments. *Philosophical Transactions of the Royal Society A: Mathematical, Physical and Engineering Sciences*, 374(2065):20150202, 4 2016.

- [13] Daniel Jurafsky and James H Martin. *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models*. 3rd edition, 2026.
- [14] Jenna Kanerva, Filip Ginter, Niko Miekka, Akseli Leino, and Tapio Salakoski. Turku Neural Parser Pipeline: An End-to-End System for the CoNLL 2018 Shared Task. In *Proceedings of the CoNLL 2018 Shared Task: Multilingual Parsing from Raw Text to Universal Dependencies*. Association for Computational Linguistics, 2018.
- [15] Marta Kutas and Steven A Hillyard. Event-related brain potentials to semantically inappropriate and surprisingly large words. *Biological Psychology*, 11(2):99–116, 1980.
- [16] Ellen F Lau, Colin Phillips, and David Poeppel. A cortical network for semantics: (de)constructing the N400. *Nature Reviews Neuroscience*, 9(12):920–933, 2008.
- [17] Garba Sani Lawal. Survey of Word Embedding Techniques in Deep Learning-Based NLP. 2022.
- [18] J MacQueen. Multivariate observations. In *Proceedings of the 5th Berkeley symposium on mathematical statistics and probability*, volume 1, pages 281–297, 1967.
- [19] Tomas Mikolov, Kai Chen, Greg Corrado, and Jeffrey Dean. Efficient Estimation of Word Representations in Vector Space, 2013.
- [20] Jiaqi Mu, Pramod Viswanath, and Suma Bhat. All-but-the-Top: Simple and Effective Postprocessing for Word Representations. 2018.
- [21] Friedemann Pulvermüller. How neurons make meaning: brain mechanisms for embodied and abstract-symbolic semantics. *Trends in Cognitive Sciences*, 17(9):458–470, 9 2013.
- [22] Peng Qi, Yuhao Zhang, Yuhui Zhang, Jason Bolton, and Christopher D Manning. Stanza: A Python Natural Language Processing Toolkit for Many Human Languages. In *Proceedings of the 58th Annual Meeting of the Association for Computational Linguistics: System Demonstrations*, 2020.
- [23] Zahra Sadeghi, James L. McClelland, and Paul Hoffman. You shall know an object by the company it keeps: An investigation of semantic representations derived from object co-occurrence in visual scenes. *Neuropsychologia*, 76:52–61, 9 2015.
- [24] Irina Simanova, Marcel van Gerven, Robert Oostenveld, and Peter Hagoort. Identifying Object Categories from Event-Related EEG: Toward Decoding of Conceptual Representations. *PLOS ONE*, 5(12):e14465–, 12 2011.
- [25] Robert L Thorndike. Who Belongs in the Family? *Psychometrika*, 18(4):267–276, 1953.

- [26] Laurens Van Der Maaten and Geoffrey Hinton. Visualizing Data using t-SNE. *Journal of Machine Learning Research*, 9:2579–2605, 11 2008.
- [27] Joe H Ward Jr. Hierarchical Grouping to Optimize an Objective Function. *Journal of the American Statistical Association*, 58(301):236–244, 3 1963.
- [28] Yang Yang, Hongjian Sun, Yu Zhang, Tiefu Zhang, Jialei Gong, Yunbo Wei, Yong Gang Duan, Minglei Shu, Yuchen Yang, Di Wu, and Di Yu. Dimensionality reduction by UMAP reinforces sample heterogeneity analysis in bulk transcriptomic data. *Cell Reports*, 36(4), 7 2021.

A Kootut ajoparametrit ja muut tiedot

Kootut työkalun ajotiedot, kirjastojen versiot sekä muu statistiikka, joka syntyi työkalua käytettäessä mutta, joka ei ollut välittömän tärkeää itse muussa raportissa.

Työssä käytetty koodi löytyy seuraavasta osoitteesta osoitteesta (04.06.2026 versio):

https://github.com/apeoskari/special_assignment

Taulukko A1: Työkalun käyttämien kirjastojen sekä muun välineistön versiot.

python	3.12.3 (main, Mar 23 2026, 19:04:32) [GCC 13.3.0]
platform	Linux-6.8.0-110-generic-x86_64-with-glibc2.39
numpy	2.4.4
pandas	3.0.2
sklearn	1.8.0
stanza	1.11.1
seaborn	0.13.2

Taulukko A2: Kaikki valittavissa olevat ajoparametrit.

LANG	"fi" tai "en" tai "sv"
AUTOMATIC	True
CLUSTERING_GRAPHS	True
CLUSTER_COUNT	250
AUTO_CLUSTER_COUNT	15
AUTO_WORDS_PER_CLUSTER	5
AUTO_WORDS_PER_BAND	4
MIN_WORD_LEN	4
MAX_WORD_LEN	10
TOTAL_WORDS	15000
LEMMA_BATCH_SIZE	2000
WORD_TYPE	NOUN
SEEDS	[]
SNAP_SEEDS	True
VIEW_CLUSTERS	20
TOP_WORDS	15
PCA	True
PCA_COUNT	250
DISTANCES	[(0.0, 0.0025), (0.005, 0.01), (0.1, 1.0)]
TARGET_WORDS	[]


Taulukko A3: Työkalun käytöstä syntynyttä tilastoa erityisesti sanojen valikointiin liittyen.

	Suomi	Englanti	Ruotsi
PCA:n selitysvoima	93,41%	92,70%	93,90%
Ainutlaatuiset kohdesanat	66	60	64
Ainutlaatuiset toiset alustussanat	195	219	167
Ainutlaatuiset ensimmäiset alustussanat	102	143	99
Poistetut sanat	33	39	64
Kolmikoita alunperin	900	900	900
Poistetut kolmikot	284	301	291
Jäljelle jääneet kolmikot	616	599	609
Läheisiä kolmikoita	246	217	208
Kohtalaisen läheisiä kolmikoita	247	210	217
Kaukaisia kolmikoita	127	172	184


Taulukko A4: Sanojen lopullisessa valikoinnissa poistetut sanat kullakin kielellä.

	Suomi	Englanti	Ruotsi
Poistetut sanat	lokakuu, elokuu, kanta, https, helmikuu, kuukaus, tammikuu, teipi, kyse, syyskuu, tavoitta, osta, alus, kristity, alumni, maaliskuu, kaupaata, single, title, siivi, toukokuu, huhtikuu, vastuutus, vasta, kohta, lippi, vaaku, kirkk, joulukuu, kplpituus, kuve, sataa, kesäkuu	lead, advisor, reply, sort, meet, send, marketing, staffing, learning, living, laugh, enjoy, forego, playing, revoke, counsellor, renew, honor, shouldn, grad, download, accept, http, confirm, save, report, play, thinking, actually, testing, manage, leave, follow, mentoring, post, kind, hiring, reading, cancel	omdömetm, juli, life, rosväxtart, antag, analys, distrikte, juni, revisa, geonam, hakmaskart, millimet, resa, batterium, specifikt, betygm, kommund, fråga, boend, december, beläge, tågväxtart, email, själv, februari, historium, insektsart, augusti, omdömen, grottor, bloggpost, bolagets, engelsk, igår, liten, oslohotell, botaukadd, varumärk, matcen, storkommun, original, omdöm, bolage, kilomet, årsmöt, september, fortsätta, lära, sund, halveö, hälsa, rummer, insatser, timma, kanton, socke, vilja, bokväxtart, mars, januari, konfer, semest, world, tysk

B Eri kielten kuvaajia



Kuva B1: Englannin t-SNE avaruus.




Kuva B2: Englannin t-SNE avaruus ja värjättyt klusterit.



Kuva B3: Ruotsin t-SNE avaruus.



Kuva B4: Ruotsin t-SNE avaruus ja värjättyt klusterit.




Kuva B5: Englannin kohdesanat t -SNE-avaruudessa.



Kuva B6: Englannin toiset kohdesanat t -SNE-avaruudessa.




Kuva B7: Englannin ensimmäiset kohdesanat t -SNE-avaruudessa.



Kuva B8: Ruotsin kohdesanat t -SNE-avaruudessa.



Kuva B9: Ruotsin toiset alustussanat t -SNE-avaruudessa.



Kuva B10: Ruotsin ensimmäiset alustussanat t -SNE-avaruudessa.